

# 数据通信原理

信号传输及处理的线性代数基础

全宇晖

二零一九年秋

# 线性模型（传输例子）

$$\mathbf{f} = \alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \cdots + \alpha_N \mathbf{v}_N$$

发送信号  
(连续)

码字1

载波1  
(连续)

码字2

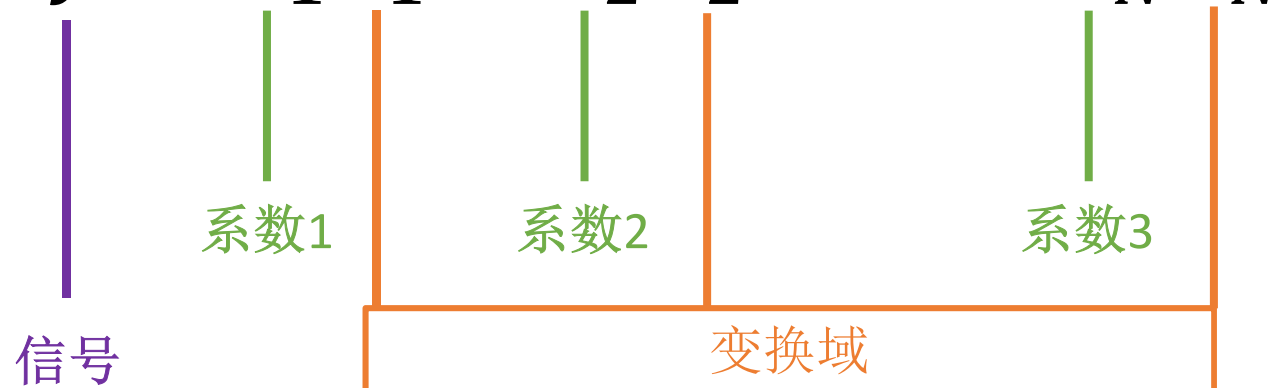
载波2  
(连续)

码字3

载波N  
(连续)

1. 假设要发送方要传输消息 $\alpha_1, \alpha_2, \dots, \alpha_N$ ，该模型意味着什么？ 离散码  $\rightarrow$  连续波
2. 接收方(采集方)拿到 $\mathbf{f}$ ，然后要做什么？  
连续波  $\rightarrow$  离散码：求解出 $\{\alpha_i\}_i$

# 线性模型（处理例子）

$$\mathbf{f} = \alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \cdots + \alpha_N \mathbf{v}_N$$


信号

系数1

系数2

系数3

变换域

通常，信号在原域难以刻画其特性，而在变换域会出现明显的统计特性，如系数 $\{\alpha_i\}_i$ 稀疏。Then?

1. 根据输入信号求解出 $\{\alpha_i\}_i$ ;
2. 对 $\{\alpha_i\}_i$ 进行处理，如稀疏化;
3. 对 $\{\alpha_i\}_i$ 进行逆变换，得到处理后的信号。

# 线性模型

$$\mathbf{f} = \alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \cdots + \alpha_N \mathbf{v}_N$$

注意在信号传输和信号处理中模型处理对象原域和变换域的差异！

传输：处理对象是 $\{\alpha_i\}$ ，原域由 $\{\mathbf{v}_i\}_i$ 定义。


处理：处理对象是 $\mathbf{f}$ ，变换域由 $\{\mathbf{v}_i\}_i$ 定义。

# 核心和基础

- $f$ 的特性（在什么空间）
- $\{\boldsymbol{v}_1, \boldsymbol{v}_2, \cdots, \boldsymbol{v}_N\}$ 的定义（用什么变换）
- $\{\alpha_1, \alpha_2, \cdots, \alpha_N\}$ 的求解

# 数字信号的线性代数基础

# 离散信号的向量表示



[1,2,3,2,-1,5,3,2,3,-1,0,0]



3	144	109	115	176
5	233	194	181	121
8	121	47	40	41
13	98	241	221	162
21	219	32	5	203

[3,5,8,13,21,144,233,121,98,219,...]

向量表示有什么好处？

# 向量空间 (Vector Space)

粗略说，向量空间 $\mathbb{V}$ 是一个定义了加法和数乘的集合，满足：



- 加法闭合：If  $\mathbf{u}, \mathbf{v} \in \mathbb{V}$ , then  $\mathbf{u} + \mathbf{v} \in \mathbb{V}$ .
- 数乘闭合：If  $\alpha \in \mathbb{C}$  and  $\mathbf{v} \in \mathbb{V}$ , then  $\alpha\mathbf{v} \in \mathbb{V}$ .
- 可交换性：If  $\mathbf{u}, \mathbf{v} \in \mathbb{V}$ , then  $\mathbf{u} + \mathbf{v} = \mathbf{v} + \mathbf{u}$ .
- 可结合性：If  $\mathbf{u}, \mathbf{v}, \mathbf{w} \in \mathbb{V}$ , then  $\mathbf{u} + (\mathbf{v} + \mathbf{w}) = \mathbf{v} + \mathbf{u} + \mathbf{w}$ .
- 存在零元： $\exists \mathbf{0}, \forall \mathbf{v} \in \mathbb{V}, \mathbf{v} + \mathbf{0} = \mathbf{v}$ .
- 加法可逆：If  $\mathbf{v} \in \mathbb{V}$ , then  $\exists -\mathbf{v} \in \mathbb{V}, \mathbf{v} + (-\mathbf{v}) = \mathbf{0}$ .
- 数乘结合：If  $\alpha, \beta \in \mathbb{C}, \mathbf{v} \in \mathbb{V}$ , then  $\alpha(\beta\mathbf{v}) = (\alpha\beta)\mathbf{v}$ .
- 加法分配：If  $\alpha \in \mathbb{C}, \mathbf{u}, \mathbf{v} \in \mathbb{V}$ , then  $\alpha(\mathbf{u} + \mathbf{v}) = \alpha\mathbf{u} + \alpha\mathbf{v}$ .
- 数乘分配：If  $\alpha, \beta \in \mathbb{C}, \mathbf{v} \in \mathbb{V}$ , then  $(\alpha + \beta)\mathbf{v} = \alpha\mathbf{v} + \beta\mathbf{v}$ .
- 存在幺元：If  $\mathbf{v} \in \mathbb{V}$ , then  $1\mathbf{v} = \mathbf{v}$ .



# 线性子空间 (Linear Subspace)

$$U \subseteq V$$

**$U$** : 具有与 **$V$** 相同的加法和数乘定义的向量空间



线性子空间对信号处理和分析有什么意义？

# 矩阵与子空间

如何理解一个矩阵**A**? (三种理解方式)

1. 线性方程组

[消元]

2. 行/列向量的集合

$$\text{span}(\mathbf{A}) \rightarrow \{w_1 \mathbf{a}_1 + w_2 \mathbf{a}_2 + \cdots + w_N \mathbf{a}_N\}$$

3. 线性变换

[像空间]和[零空间]

# 零空间(Null Space)和像空间(Range)

$$\begin{aligned} \text{null}(\mathbf{A}) &= \{\mathbf{x}: \mathbf{A}\mathbf{x} = \mathbf{0}\} \\ \text{range}(\mathbf{A}) &\rightarrow \{\mathbf{A}\mathbf{x}: \mathbf{x} \in \mathbb{R}^N\} \end{aligned}$$

零空间和像空间是向量空间吗？是线性子空间吗？

$\text{span}(\mathbf{A})$ 和 $\text{range}(\mathbf{A})$ 有什么联系？

# 向量的内积和范数

- 内积


$$\langle \mathbf{u}, \mathbf{v} \rangle = \mathbf{v}^T \mathbf{u} = \sum_{n=1}^N u_n v_n = \|\mathbf{u}\| \|\mathbf{v}\| \cos \theta$$

- $l_2$  范数

$$\|\mathbf{u}\|_2^2 = \langle \mathbf{u}, \mathbf{u} \rangle = \mathbf{u}^T \mathbf{u} = \sum_{n=1}^N u_n^2$$

- 投影

$$\mathbf{v}_u = \frac{\|\mathbf{u}\| \cos \theta}{\|\mathbf{v}\|} \mathbf{v} = \frac{\mathbf{v}^T \mathbf{u}}{\mathbf{v}^T \mathbf{v}} \mathbf{v} = \mathbf{v} \frac{\mathbf{v}^T \mathbf{u}}{\mathbf{v}^T \mathbf{v}}$$



# 向量的其他范数


- $l_0$  范数

$$\|\mathbf{x}\|_0 = \#\{j: \mathbf{x}_j \neq 0\}$$

等高线图像？


- $l_1$  范数

$$\|\mathbf{x}\|_1 = \sum_i |\mathbf{x}_i|$$




- $l_2$  范数

$$\|\mathbf{x}\|_2 = \sqrt{\sum_i \mathbf{x}_i^2}$$



- $l_\infty$  范数

$$\|\mathbf{x}\|_\infty = \max_i |\mathbf{x}_i|$$



- $l_p$  范数

$$\|\mathbf{x}\|_p = \left( \sum_{i=1}^N |\mathbf{x}_i|^p \right)^{\frac{1}{p}}$$